LAPORAN PENUGASAN MINGGU 03: PEMBELAJARAN MESIN

Baseline Model Training, Cross-Validation Strategy, & Performance Metrics Evaluation

Mata Kuliah: Pembelajaran Mesin (S1 - 3 SKS) | Semester Gasal 2026/2027
Dosen Pengampu: Dr. Irwansyah Saputra, M.Kom.

A. IDENTITAS KELOMPOK & KONFIRMASI DATASET OBJEK STUDI KASUS

No	NIM	Nama Mahasiswa & Peran Kerja Tim
1	12250158	Muhammad Rizqi Saputra — Koordinator Tim, Dokumentator, & QC
2	12250162	Dian Nur Cahya — Lead Analis Data & Pipeline Validation
3	12250161	Dicky Handia — Lead Model Engineer (Pelatihan & Evaluasi Model)

Ringkasan	Keterangan
Nama Instansi	Kantor Notaris & PPAT Aries Buwana, Dipl.-Ing., SH, MKn (Jakarta Barat)
Target Prediksi (y)	Target_Label (Biner: 0 = Tepat Waktu, 1 = Terlambat)
Dimensi Matriks Akhir	169 baris x 18 kolom fitur (setelah encoding)

B. STRATEGI PEMISAHAN DATA (TRAIN-TEST SPLIT) & CROSS-VALIDATION

Data dibagi 80:20 secara stratified (random_state=42) SEBELUM transformasi apa pun, lalu model dievaluasi dengan 5-Fold Stratified Cross-Validation hanya pada data latih. Winsorizing, StandardScaler, dan One-Hot Encoding berada di dalam Pipeline sehingga di-fit ulang pada setiap lipatan latih (prinsip Split-Before-Transform), dan data uji hanya di-transform. Kolom *ada_rups* bernilai 0 untuk akta tanpa RUPS ("Tidak Relevan"), tidak di-drop, sesuai catatan dosen.

Komponen Pemisahan	Jumlah Baris / Ukuran Partisi	Keterangan / Justifikasi Metodologi
Data Latih (X_train, y_train)	135 baris (80%): 26 Terlambat, 109 Tepat Waktu	Digunakan untuk proses fitting model & validasi silang 5-fold.
Data Uji (X_test, y_test)	34 baris (20%): 7 Terlambat, 27 Tepat Waktu	Data unseen yang diisolasi total untuk evaluasi performa akhir.
Metode Pemisahan Data	Stratified Random Split (train_test_split, stratify=y, random_state=42)	Dipilih agar rasio kelas Terlambat (±19.5%) sama pada data latih dan uji; kelas minoritas sangat kecil sehingga split acak tanpa stratifikasi berisiko menghasilkan data uji tanpa berkas terlambat.
Skema Validasi Silang (CV)	5-Fold Stratified Cross-Validation (shuffle=True, random_state=42)	Diterapkan pada data latih saja; setiap lipatan mempertahankan rasio kelas dan menghasilkan rata-rata serta simpangan baku skor sebagai ukuran stabilitas model.

C. SPESIFIKASI 3 ALGORITMA MACHINE LEARNING & POTONGAN KODE PYTHON

Kelompok memilih tiga algoritma dari tiga keluarga berbeda (Linear, Tree, Ensemble) beserta justifikasi ilmiahnya:

Model Ke-	Nama Algoritma ML	Keluarga Algoritma	Alasan Pemilihan & Hyperparameter Kunci
Model 1	Logistic Regression	Linear / Probabilistic Model	Baseline linier yang mudah diinterpretasi. class_weight='balanced', C=1.0 (regularisasi L2), max_iter=1000; dipakai bersama winsorizing persentil ke-95 dan StandardScaler.
Model 2	Decision Tree	Tree-based / Non-Linear	Menangkap relasi non-linear dan interaksi fitur (mis. jenis akta dengan hari masuk) tanpa scaling. max_depth=4, min_samples_leaf=5, class_weight='balanced' untuk membatasi overfitting pada data kecil.
Model 3	Random Forest	Ensemble Learning (Bagging)	Rata-rata banyak pohon menurunkan varians dan lebih stabil daripada satu pohon; tahan pencilan. n_estimators=300, max_depth=5, min_samples_leaf=3, class_weight='balanced_subsample'.

Potongan Kode Python (Pipeline Scikit-Learn / XGBoost):

```python
import numpy as np
import pandas as pd
from sklearn.base import BaseEstimator, TransformerMixin
from sklearn.compose import ColumnTransformer
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix
from sklearn.model_selection import StratifiedKFold, cross_validate, train_test_split
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.tree import DecisionTreeClassifier

SEED = 42
FITUR_NUM = ['jumlah_penghadap', 'sla_hari', 'antrean_berjalan']
FITUR_KAT = ['kategori_akta', 'hari_masuk']


class Winsorizer(BaseEstimator, TransformerMixin):
    """Clip jumlah_penghadap pada persentil ke-95; batas dihitung dari data latih."""
    def __init__(self, kolom='jumlah_penghadap', q=0.95):
        self.kolom, self.q = kolom, q

    def fit(self, X, y=None):
        self.batas_ = X[self.kolom].quantile(self.q)
        return self

    def transform(self, X):
        return X.assign(**{self.kolom: X[self.kolom].clip(upper=self.batas_)})


def buat_pipeline(model, skala):
    """skala=True : winsorizing + StandardScaler (model linear)
       skala=False: tanpa scaling (model pohon tidak sensitif skala)"""
    num = StandardScaler() if skala else 'passthrough'
    prep = ColumnTransformer(
        [('num', num, FITUR_NUM),
         ('cat', OneHotEncoder(handle_unknown='ignore'), FITUR_KAT)],
        remainder='passthrough')  # ada_rups, bulan_sin, bulan_cos
    langkah = [('winsor', Winsorizer())] if skala else []
    return Pipeline(langkah + [('prep', prep), ('model', model)])


MODEL = {
    'Logistic Regression': buat_pipeline(
        LogisticRegression(class_weight='balanced', C=1.0, max_iter=1000,
                           random_state=SEED), skala=True),
    'Decision Tree': buat_pipeline(
```

```
        DecisionTreeClassifier(max_depth=4, min_samples_leaf=5,
                               class_weight='balanced', random_state=SEED), skala=False),
    'Random Forest': buat_pipeline(
        RandomForestClassifier(n_estimators=300, max_depth=5, min_samples_leaf=3,
                               class_weight='balanced_subsample', random_state=SEED,
                               n_jobs=-1), skala=False),
}

# 1. Train-Test Split 80:20 stratified: dilakukan SEBELUM transformasi apa pun
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=SEED)

# 2. 5-Fold Stratified CV pada data latih. Winsorizing/scaling/encoding ada di dalam
#    Pipeline, jadi di-fit ulang pada tiap lipatan latih (tanpa data leakage)
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=SEED)
metrik = {'f1': 'f1', 'precision': 'precision', 'recall': 'recall',
          'roc_auc': 'roc_auc', 'pr_auc': 'average_precision'}
hasil_cv, model_latih = {}, {}
for nama, pipe in MODEL.items():
    hasil_cv[nama] = cross_validate(pipe, X_train, y_train, cv=cv, scoring=metrik,
                                    return_train_score=True)
    model_latih[nama] = pipe.fit(X_train, y_train)  # fit akhir pada seluruh data latih

# 3. Prediksi & evaluasi pada data uji
y_pred = {n: m.predict(X_test) for n, m in model_latih.items()}
y_prob = {n: m.predict_proba(X_test)[:, 1] for n, m in model_latih.items()}
for nama in MODEL:
    print(nama)
    print(confusion_matrix(y_test, y_pred[nama]))
    print(classification_report(y_test, y_pred[nama], digits=3, zero_division=0))
```

D. EVALUASI KINERJA MODEL & VISUALISASI METRIK PREDIKSI

Evaluasi pada Testing Set (34 berkas, 7 terlambat). Precision, Recall, dan F1 pada tabel pertama adalah rata-rata macro dua kelas; metrik khusus kelas Terlambat (fokus operasional) ada pada tabel kedua.

Algoritma	Accuracy	Precision	Recall	F1-Score (Macro)	ROC-AUC / Metrik Utama
Model 1: Logistic Regression	58.8%	0.482	0.476	0.471	ROC-AUC 0.571 PR-AUC 0.261
Model 2: Decision Tree	67.6%	0.529	0.532	0.530	ROC-AUC 0.476 PR-AUC 0.250
Model 3: Random Forest	67.6%	0.383	0.426	0.404	ROC-AUC 0.481 PR-AUC 0.211

Metrik kelas Terlambat (kelas minoritas) pada data uji. TP/FN/FP/TN dihitung dengan "Terlambat" sebagai kelas positif:

Algoritma	Precision (Terlambat)	Recall (Terlambat)	F1-Score (Terlambat)	PR-AUC	TP / FN / FP / TN
Model 1: Logistic Regression	0.182	0.286	0.222	0.261	2 / 5 / 9 / 18
Model 2: Decision Tree	0.250	0.286	0.267	0.250	2 / 5 / 6 / 21
Model 3: Random Forest	0.000	0.000	0.000	0.211	0 / 7 / 4 / 23

Classification Report pada Testing Set

Model 1: Logistic Regression

	precision	recall	f1-score	support
Tepat Waktu (0)	0.783	0.667	0.720	27
Terlambat (1)	0.182	0.286	0.222	7
accuracy			0.588	34
macro avg	0.482	0.476	0.471	34
weighted avg	0.659	0.588	0.618	34

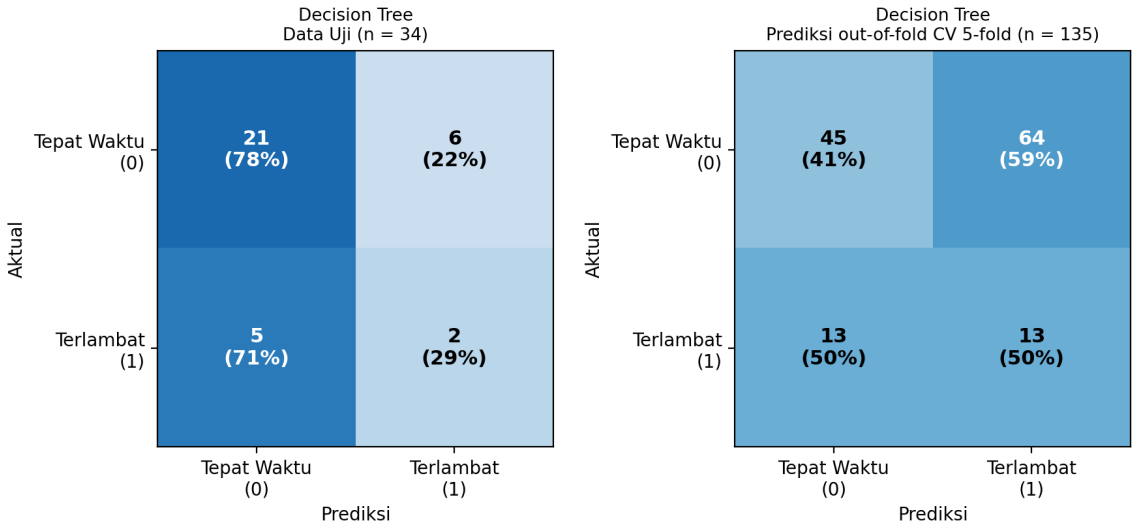
Model 2: Decision Tree

	precision	recall	f1-score	support
Tepat Waktu (0)	0.808	0.778	0.792	27
Terlambat (1)	0.250	0.286	0.267	7
accuracy			0.676	34
macro avg	0.529	0.532	0.530	34
weighted avg	0.693	0.676	0.684	34

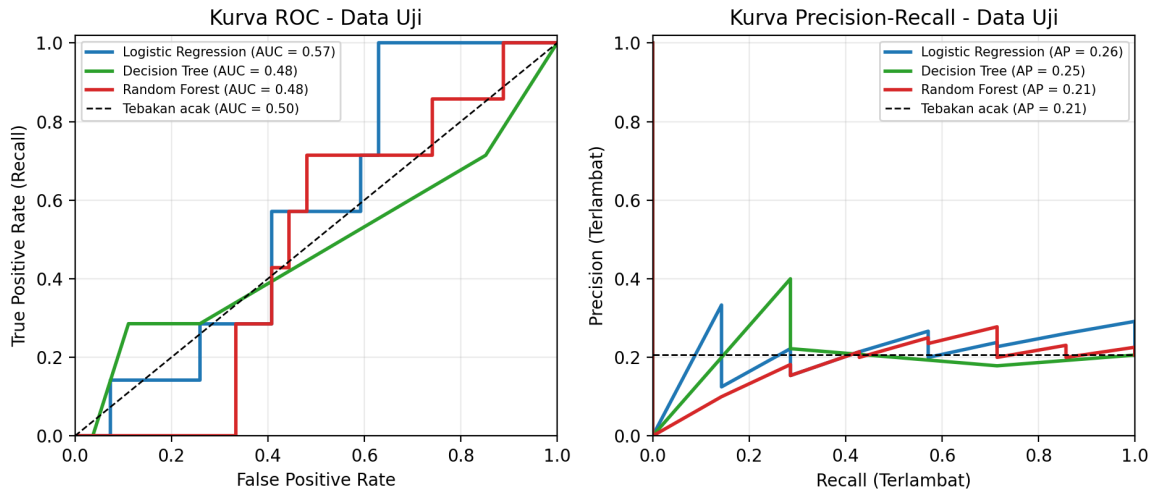
Model 3: Random Forest

	precision	recall	f1-score	support
Tepat Waktu (0)	0.767	0.852	0.807	27
Terlambat (1)	0.000	0.000	0.000	7
accuracy			0.676	34
macro avg	0.383	0.426	0.404	34
weighted avg	0.609	0.676	0.641	34

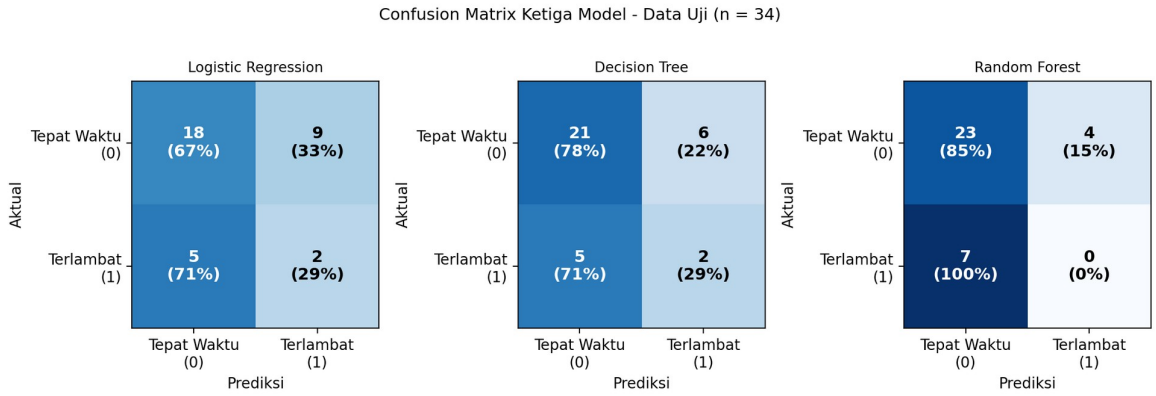
Lampiran Visualisasi Metrik (Minimal 2 Gambar)



Gambar 1. Heatmap Confusion Matrix model terbaik (Decision Tree): data uji (kiri) dan prediksi out-of-fold validasi silang (kanan).



Gambar 2. Kurva ROC (kiri) dan Precision-Recall (kanan) komparatif tiga model pada data uji.



Gambar 3. Confusion Matrix ketiga model pada data uji.

E. ANALISIS KOMPARATIF, DIAGNOSA OVERFITTING, & REKOMENDASI MODEL TERBAIK

Skor yang dibandingkan adalah F1-Score kelas Terlambat. "Skor CV Data Latih" adalah rata-rata F1 pada lipatan latih (5-fold), "Skor Data Uji" adalah F1 pada testing set, dan Gap = (latih - uji) dalam poin persentase. Kriteria: Underfit bila kedua skor < 0.50; Overfit bila gap > 10 poin; selain itu Good Fit. Skor validasi silang (rata-rata ± simpangan baku) dicantumkan sebagai pembanding yang lebih stabil daripada data uji yang kecil.

Algoritma	Skor CV Data Latih (Train)	Skor Data Uji (Test)	Selisih Gap (%)	Diagnosa (Overfit/Underfit/Good Fit)
Model 1: Logistic Regression	0.501	0.222	27.8%	**Overfit** (F1 validasi CV: 0.241 ± 0.086)
Model 2: Decision Tree	0.516	0.267	25.0%	**Overfit** (F1 validasi CV: 0.247 ± 0.065)
Model 3: Random Forest	0.744	0.000	74.4%	**Overfit** (F1 validasi CV: 0.095 ± 0.124)

Narasi Diskusi Analitik & Kesimpulan Model Terpilih (Minimal 2 Paragraf)

Paragraf 1. Pada data uji (34 berkas, 7 di antaranya terlambat), accuracy ketiga model berkisar 58.8% hingga 67.6%. Angka ini kurang informatif karena model yang selalu menebak "Tepat Waktu" sudah memperoleh accuracy 79.4% tanpa mendeteksi satu pun keterlambatan, sehingga perbandingan difokuskan pada Precision, Recall, dan F1-Score kelas Terlambat. Logistic Regression mendeteksi 2 dari 7 berkas terlambat (recall 0.29) dengan precision 0.18 dan F1 0.22; Decision Tree mendeteksi 2 dari 7 berkas terlambat (recall 0.29) dengan precision 0.25 dan F1 0.27; Random Forest mendeteksi 0 dari 7 berkas terlambat (recall 0.00) dengan precision 0.00 dan F1 0.00. Logistic Regression dan Decision Tree memiliki recall yang sama (0.29); Decision Tree unggul pada precision, sehingga tidak tampak trade-off precision-recall yang tajam pada data uji ini. Diagnosa train vs test: Logistic Regression (F1 kelas Terlambat latih 0.50 turun menjadi 0.22 pada data uji), Decision Tree (F1 kelas Terlambat latih 0.52 turun menjadi 0.27 pada data uji) dan Random Forest (F1 kelas Terlambat latih 0.74 turun menjadi 0.00 pada data uji) terindikasi overfitting. Rata-rata ROC-AUC validasi silang ketiga model paling tinggi hanya 0.50, masih dekat 0.50 (tebakan acak). Ini konsisten dengan temuan EDA Tugas 02 bahwa korelasi linear fitur terhadap target lemah, sehingga fitur yang ada belum cukup menjelaskan keterlambatan.

Paragraf 2. Model yang dipilih sebagai model terbaik kelompok adalah Decision Tree. Pemilihan didasarkan pada rata-rata F1-Score kelas Terlambat pada validasi silang 5-fold (0.25 ± 0.07), bukan pada data uji, agar data uji tetap murni sebagai penilai akhir. Pada data uji model ini mencapai recall 0.29, precision 0.25, F1 0.27, dan ROC-AUC 0.48. Secara operasional, kantor lebih diuntungkan oleh model yang peka (recall tinggi): berkas yang diprediksi terlambat dapat diprioritaskan petugas sejak berkas masuk, sedangkan alarm palsu hanya berbiaya pengecekan tambahan. Ketidakseimbangan kelas ditangani dengan class_weight, bukan SMOTE, karena kelas Terlambat hanya 26 berkas pada data latih sehingga data sintetis berisiko tidak representatif. Mengingat sinyal prediktifnya masih lemah (ROC-AUC mendekati tebakan acak), model ini belum layak dipakai sebagai alat peringatan dini di kantor dan diposisikan sebagai baseline pembanding untuk iterasi berikutnya setelah data dan fitur diperkaya.

Paragraf 3. Keterbatasan utama adalah ukuran data (169 berkas). Data uji hanya memuat 7 berkas terlambat sehingga satu prediksi berbeda mengubah recall sebesar 14 poin persentase; seluruh angka pada laporan ini bersifat indikatif. Langkah lanjutan yang direncanakan: menambah data periode sebelumnya, menambah fitur kelengkapan berkas awal dan instansi tujuan (BPN, AHU, KPP Pratama), menyetel ambang keputusan (threshold) untuk menaikkan recall, serta memakai Repeated Stratified K-Fold agar estimasi lebih stabil.

F. LEMBAR KOMITMEN & INTEGRITAS AKADEMIK

Kami menyatakan dengan sebenarnya bahwa seluruh proses pengolahan data, pelatihan 3 algoritma Machine Learning, dan penyusunan metrik evaluasi pada laporan ini adalah hasil karya autentik kelompok kami sendiri tanpa rekayasa angka. Seluruh kode Python dapat diuji ulang secara langsung.

Kota/Tanggal: Jakarta, 15 Oktober 2026
Koordinator Tim: Muhammad Rizqi Saputra (NIM: 12250158)