LAPORAN PENUGASAN MINGGU 04
PEMBELAJARAN MESIN

Hyperparameter Tuning, Feature Importance, dan Model Explainability

Semester Gasal 2026/2027
Dosen Pengampu Dr. Irwansyah Saputra, M.Kom.

A. IDENTITAS KELOMPOK DAN MODEL BASELINE TERBAIK

No	NIM	Nama dan peran
1	12250158	Muhammad Rizqi Saputra Koordinator Tim, Dokumentator, dan QC
2	12250162	Dian Nur Cahya Analis Data dan Pipeline Validation
3	12250161	Dicky Handia Model Engineer, Tuning, dan Explainability

Kami melanjutkan penelitian tentang keterlambatan penyelesaian berkas pada Kantor Notaris & PPAT Aries Buwana, Dipl.-Ing., SH, MKn, Jakarta Barat. Laporan ini membahas penalaan Decision Tree serta penjelasan hasil prediksinya. Data yang digunakan adalah 169 catatan berkas kantor, sesuai jumlah data pada Tugas 03.

Komponen	Keterangan
Target prediksi	Terlambat = 1 jika lama penyelesaian dalam hari kalender melebihi SLA; selain itu = 0.
Komposisi data	33 berkas terlambat dan 136 tepat waktu. Train: 135 berkas, termasuk 26 terlambat. Test: 34 berkas, termasuk 7 terlambat.
Baseline dari Tugas 03	Decision Tree; max_depth=4, min_samples_leaf=5, class_weight=balanced, random_state=42.
Hasil yang tercatat pada Tugas 03	Test F1 positif 0,267; recall 0,286; AP 0,250; ROC-AUC 0,476.
Sasaran Tugas 04	Menguji parameter secara teratur, membandingkan train/CV/test, menghitung permutation importance, dan menjelaskan kasus dengan SHAP.

Pada pengujian ulang, AP baseline 0,178 berubah menjadi 0,196 setelah tuning. Ambang OOF 0,11 menangkap 4 dari 7 keterlambatan dengan 18 alarm palsu. Hasil ini menunjukkan bahwa aturan prioritas masih perlu diperbaiki sebelum dipakai di kantor. [1][2][3]

B. DESAIN RUANG PENCARIAN HYPERPARAMETER DAN STRATEGI TUNING

Kami tetap menggunakan Decision Tree agar pengembangan mengikuti model terpilih pada Tugas 03. Lima parameter diuji untuk mencari aturan yang cukup sederhana dan tidak terlalu bergantung pada contoh data latih. Pemilihan dilakukan berdasarkan Average Precision (AP), karena berkas terlambat merupakan kelas minoritas dan kantor membutuhkan urutan risiko yang dapat diperiksa.

Hyperparameter	Tipe	Nilai yang diuji	Nilai terpilih dan alasan pengujian
max_depth	Integer	1, 2, 3, 4, 5	4 Membatasi panjang percabangan agar pohon tidak terlalu rinci.
min_samples_leaf	Integer	2, 5, 10, 15	15 Menguji dukungan data minimum pada setiap daun.
min_samples_split	Integer	2, 10	2 Membatasi kapan suatu simpul boleh dipecah.
ccp_alpha	Float	0; 0,002; 0,010; 0,020	0.0 Menguji pemangkasan cabang berdasarkan kompleksitas pohon.
class_weight	String	None, balanced	None Membandingkan tanpa bobot dengan pembobotan kelas minoritas.

Jumlah kombinasi adalah 5 × 4 × 2 × 4 × 2 = 320. Setiap kandidat menjalani 5-fold CV pada train. Skor AP CV tertinggi pada pencarian final adalah 0,2313. Nilai terpilih merupakan hasil terbaik di ruang pencarian ini; tidak berarti seluruh konfigurasi lain sudah terbukti lebih buruk.

Rank	Depth	Leaf min	Split min	Pruning	Bobot	AP CV
1	4	15	10	0,000	None	0,2313
1	4	15	2	0,000	None	0,2313
3	5	15	10	0,000	None	0,2300

Leaf minimal 15 memberi dukungan data lebih besar daripada baseline yang memakai 5. Depth 4 membatasi panjang aturan. Pruning 0 dan bobot None dipilih karena mencapai AP CV tertinggi bersama parameter lain; pembobotan balanced tidak dipaksakan. Dua kandidat teratas seri. Nilai split 2 terpilih menurut urutan grid; pada leaf minimal 15, split 2 dan 10 tidak menambah batas efektif yang berbeda.

Precision, recall, F1 positif, Macro F1, serta jumlah alarm tetap dilaporkan. AP dipakai untuk memilih kualitas peringkat, sedangkan ambang keputusan dibahas terpisah. Karena tujuan kantor adalah mendeteksi risiko, kenaikan accuracy tidak langsung dianggap sebagai keberhasilan.

B.1 Pembagian data dan pencegahan kebocoran informasi

Data dibagi 80:20 dengan stratifikasi target dan random_state=42. Seluruh pembentukan fitur, imputasi, dan encoding berada dalam Pipeline. Pada setiap fold, histori antrean hanya berasal dari fold latih. Tanggal selesai berkas yang sedang diprediksi tidak dipakai untuk membentuk fiturnya. [4]

Tahap	Data yang digunakan	Tujuan
Train	135 berkas; 26 terlambat dan 109 tepat waktu.	Memilih parameter serta ambang keputusan.
Inner CV	Lima fold pada train.	Membandingkan 320 kandidat.
Outer CV	Lima fold pada train; setiap fold mengulang inner search.	Menilai prosedur pemilihan parameter tanpa memakai test.
Test	34 berkas; 7 terlambat dan 27 tepat waktu.	Evaluasi setelah parameter dan ambang ditetapkan.

```
import sys, pandas as pd
sys.path.insert(0, "work")
from sklearn.model_selection import GridSearchCV, train_test_split
from analisis_tugas04_kantor import pipeline, cv5, GRID
from fitur_notaris import RAW
data = pd.read_csv("data/berkas_notaris.csv")
durasi = (pd.to_datetime(data["tgl_selesai"]) -
          pd.to_datetime(data["tgl_masuk"])).dt.days
y = (durasi > data["sla_hari"]).astype(int)
X_train, X_test, y_train, y_test = train_test_split(
    data[RAW], y, test_size=0.20, stratify=y, random_state=42)
search = GridSearchCV(
    pipeline(), GRID, scoring="average_precision", cv=cv5(),
    refit=True, n_jobs=2, return_train_score=True)
search.fit(X_train, y_train)
best_model = search.best_estimator_
```

Jumlah penghadap dan SLA mengikuti nilai pada rekap. Hari dan koordinat bulan dihitung dari tanggal masuk. Indikator RUPS bernilai 1 hanya jika tanggalnya tidak melampaui tanggal masuk. Sebanyak 156 tanggal RUPS kosong tetap dipertahankan sebagai indikator 0; 10 tanggal yang terjadi setelah penerimaan juga tidak dianggap tersedia pada awal.

Antrean didefinisikan sebagai berkas latih lain yang sudah masuk sebelum hari penerimaan dan belum selesai sebelum hari tersebut. Berkas yang selesai pada hari itu masih dihitung terbuka pada awal hari. Definisi ini memakai tanggal pada histori latih, bukan hasil selesai dari sampel uji. Hitungannya terbatas pada rekap yang tersedia dan belum mencakup seluruh pekerjaan kantor.

C. EVALUASI KOMPARASI PERFORMA BASELINE DAN TUNED MODEL

Jumlah data dan komposisi target sesuai Tugas 03. Namun, pembentukan antrean kini dilakukan ulang di dalam setiap fold dan RUPS dibatasi menurut waktu penerimaan. Oleh karena itu kami melatih ulang konfigurasi baseline Tugas 03. Baseline ulang dan tuned memakai baris, fitur, serta pembagian train-test yang sama agar delta tuning dapat dibandingkan dengan adil.

Metrik	Baseline Train	Baseline Test	Tuned Train	Tuned Test dan delta
Accuracy	0,674	0,382	0,807	0,794 +41,2 pp
Precision positif	0,350	0,000	0,000	0,000 +0,0 pp
Recall positif	0,808	0,000	0,000	0,000 +0,0 pp
F1 positif	0,488	0,000	0,000	0,000 +0,0 pp
Macro F1	0,625	0,277	0,447	0,443 +16,6 pp
ROC-AUC	0,807	0,302	0,741	0,381 +7,9 pp
Average Precision	0,458	0,178	0,342	0,196 +1,8 pp

Semua skor pada tabel utama dihitung dari eksperimen saat ini. Train adalah hasil fit pada seluruh 135 data latih. Ambang pada tabel ini tetap 0,50. F1 positif dan Macro F1 disajikan terpisah, mengikuti perbedaan metrik yang dijelaskan pada Tugas 03.

Riwayat Tugas 03	Nilai yang tercantum
F1 lipatan latih dan F1 validasi CV	0,516 dan 0,247 ± 0,065
F1, precision, recall positif pada test	0,267; 0,250; 0,286
Accuracy dan Macro F1 pada test	0,676 dan 0,530
AP, ROC-AUC, dan TP / FN / FP / TN	0,250; 0,476; 2 / 5 / 6 / 21

Angka historis dipertahankan sesuai laporan lama; 0,516 adalah rerata fold latih, bukan skor fit akhir pada seluruh train. F1 test tuned 0,50 lebih rendah daripada 0,267 pada Tugas 03. Setelah ambang OOF, F1 menjadi 0,276. Perbandingan lintas tugas ini bersifat deskriptif karena pembentukan fitur berubah. Encoder saat ini menghasilkan 25 kolom, sedangkan Tugas 03 menyebut 18. Delta tuning yang setara menggunakan baseline ulang pada tabel utama.

C.1 Validasi silang dan diagnosis overfitting

Prosedur	AP outer CV	F1 positif outer CV	Recall outer CV	F1 latih outer
Baseline 0,50	0,196 ± 0,041	0,242 ± 0,083	0,427 ± 0,101	0,519 ± 0,025
Tuned 0,50	0,198 ± 0,024	0,199 ± 0,153	0,313 ± 0,272	0,517 ± 0,080
Tuned dan ambang OOF	0,198 ± 0,024	0,297 ± 0,083	0,713 ± 0,348	0,458 ± 0,115

Angka di atas adalah rata-rata lima outer fold dan simpangan baku sampel. Setiap outer fold memilih parameter dan ambangnya dari outer train. Karena model per fold dapat berbeda, skor ini tidak sama dengan menjalankan model final pada data latihnya sendiri. [5]

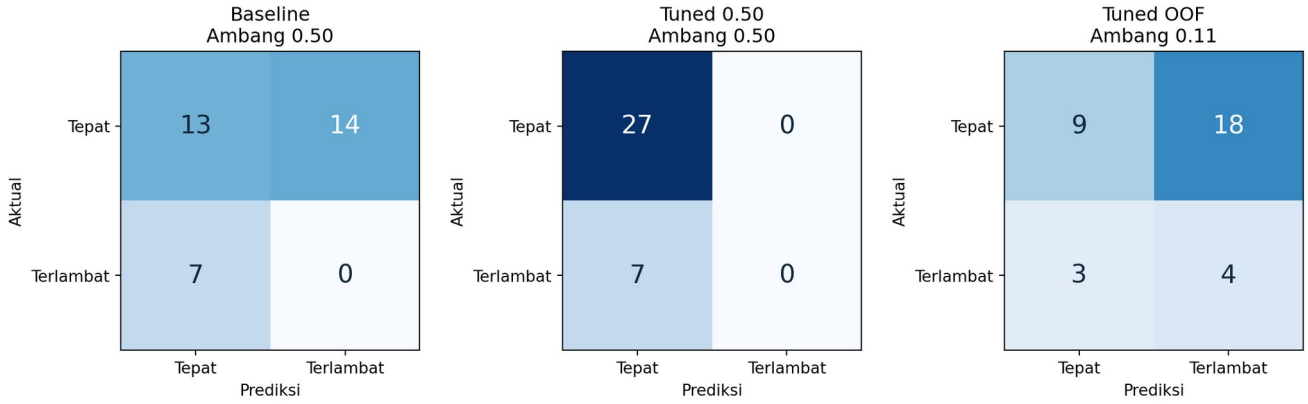
Fold	AP baseline	AP tuned	Ambang dari inner	F1 tuned dan ambang
1	0,197	0,180	0,13	0,312
2	0,160	0,173	0,27	0,308
3	0,265	0,224	0,37	0,353
4	0,168	0,222	0,33	0,357
5	0,191	0,191	0,42	0,154

AP outer baseline 0,196 ± 0,041 berubah menjadi 0,198 ± 0,024. Pada ambang 0,50, F1 outer berubah dari 0,242 ± 0,083 menjadi 0,199 ± 0,153. Setelah pemilihan ambang OOF, F1 outer adalah 0,297 ± 0,083. Perbedaan antar-fold menunjukkan hasil masih sensitif terhadap sampel.

Pemeriksaan train dan test	Baseline	Tuned 0,50
F1 train dan test	0,488 dan 0,000	0,000 dan 0,000
Gap F1 train dikurangi test	+48,8 pp	+0,0 pp
AP train dan test	0,458 dan 0,178	0,342 dan 0,196
Pohon final	Depth maksimal 4; leaf minimal 5	Depth 4; 7 daun

Gap F1 tuned yang kecil tidak menunjukkan good fit karena pada ambang 0,50 model final tidak memprediksi satu pun berkas terlambat, baik di train maupun test. Masalah utamanya adalah batas keputusan dan lemahnya pemisahan kelas. Pada baseline, gap train-test juga menunjukkan pola data latih belum terbawa dengan baik ke data uji.

C.2 Confusion matrix dan perbandingan ambang



Gambar 1. Confusion matrix pada 34 berkas uji yang sama.

Model dan ambang	TP / FN	FP / TN	Precision	Recall	F1 positif	Alarm
Baseline 0,50	0 / 7	14 / 13	0,000	0,000	0,000	41,2%
Tuned 0,50	0 / 7	0 / 27	0,000	0,000	0,000	0,0%
Tuned 0,25	0 / 7	9 / 18	0,000	0,000	0,000	26,5%
Tuned OOF 0,11	4 / 3	18 / 9	0,182	0,571	0,276	64,7%

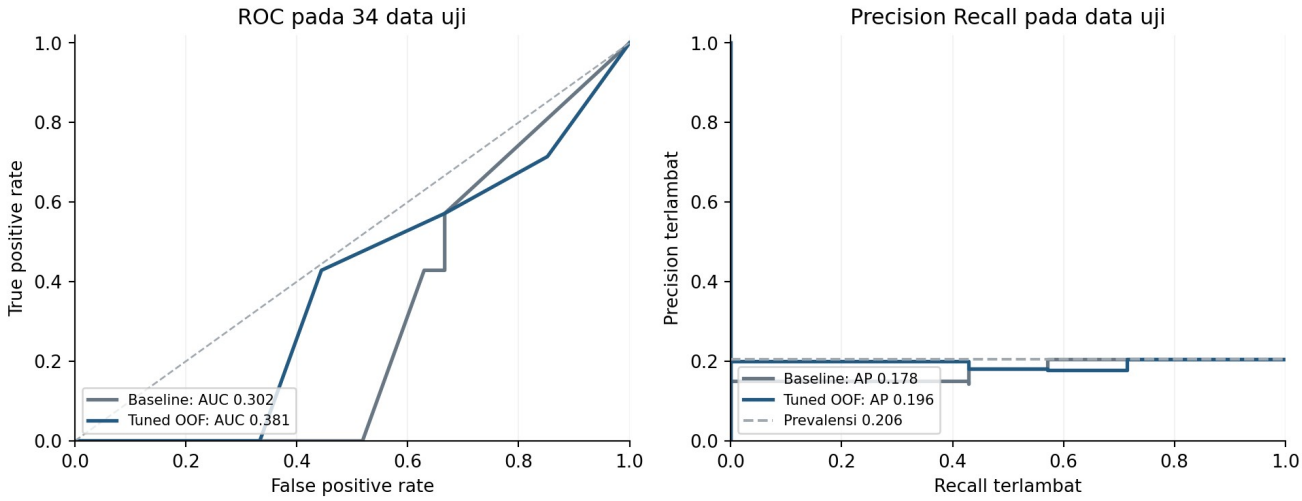
Saran dosen untuk menurunkan ambang ke 0,25 sudah diuji. Pada dataset ini, model tuned masih melewatkan 7 keterlambatan dan menghasilkan 9 alarm palsu. Jadi, penurunan ke 0,25 belum memberi hasil yang diharapkan. Temuan ini tetap ditulis sesuai hasil pengujian.

Ambang OOF 0,11 menangkap 4 dari 7 keterlambatan, tetapi memberi 18 alarm palsu. Sebanyak 22 dari 34 berkas mendapat alarm. Bagi staf, jumlah ini berarti pemeriksaan tambahan yang cukup besar; recall perlu dibaca bersama precision dan kapasitas pemeriksaan.

Pembanding sederhana	Accuracy	Recall	F1 positif	AP
Selalu tepat waktu	0,794	0,000	0,000	0,206
Selalu terlambat	0,206	1,000	0,341	0,206

Accuracy tuned 0,50 sama dengan strategi selalu menebak tepat waktu. Karena tidak menangkap keterlambatan, angka tersebut tidak digunakan sebagai alasan bahwa model telah berhasil. Sebaliknya, selalu menebak terlambat menghasilkan recall penuh dengan beban alarm pada semua berkas.

C.3 Kurva ROC PR dan ketidakpastian hasil



Gambar 2. ROC dan Precision Recall berdasarkan skor pada data uji.

AP test baseline 0,178 berubah menjadi 0,196 setelah tuning, dengan delta +1,8 pp. Prevalensi keterlambatan pada test adalah 0,206. AP tuned masih di bawah acuan tersebut, sehingga kemampuan mengurutkan risiko belum kuat. AP memakai average_precision_score dan berbeda dari luas PR yang dihitung dengan metode trapezoid. [6]

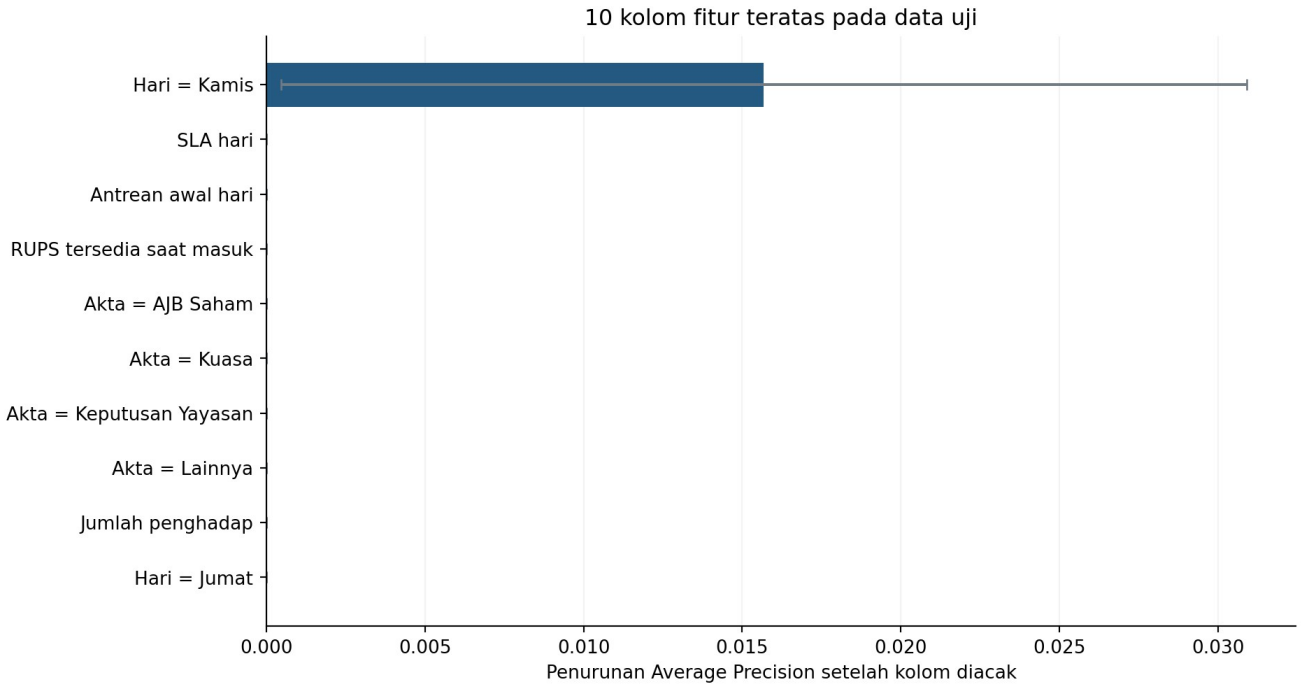
Delta pada test yang sama	Rata-rata bootstrap	Interval persentil 95%
AP dari tuning	+2,2 pp	-0,0155 s.d. 0,0892
F1 pada ambang 0,50	+0,0 pp	0,0000 s.d. 0,0000
F1 termasuk ambang OOF	+27,3 pp	0,1212 s.d. 0,4286

Interval berasal dari 2.000 bootstrap berpasangan dan terstratifikasi. Kedua model dinilai pada indeks berkas yang sama dalam setiap pengulangan. Interval menggunakan skala skor 0 sampai 1, sedangkan rata-rata delta memakai poin persentase. Resampling ini menilai variasi sampel uji dengan model tetap; tidak mencakup seluruh ketidakpastian pelatihan.

Test hanya memuat tujuh keterlambatan. Satu prediksi yang berubah menggeser recall sekitar 14,3 poin persentase. Karena itu hasil belum cukup untuk menyatakan bahwa model akan memberi mutu yang sama pada periode baru. Pengujian tambahan perlu memakai catatan berkas yang belum pernah masuk pemilihan model.

D. ANALISIS PERMUTATION FEATURE IMPORTANCE

Permutation importance dihitung pada 25 kolom hasil encoding data uji, setelah transformasi dari train dibekukan. Setiap kolom diacak 100 kali dan dinilai dengan AP. Grafik menampilkan 10 mean tertinggi; tidak ada nilai importance yang diisi secara manual. Cara ini menilai perubahan skor pada test dan menghindari penggunaan Gini importance sebagai dasar peringkat. [6]



Gambar 3. Top 10 kolom hasil encoding. Galat menunjukkan ±1 simpangan baku pengacakan.

Kolom fitur	Mean penurunan AP	Simpangan baku
Hari = Kamis	0,0157	0,0152
SLA hari	0,0000	0,0000
Antrean awal hari	0,0000	0,0000
RUPS tersedia saat masuk	0,0000	0,0000
Akta = AJB Saham	0,0000	0,0000
Akta = Kuasa	0,0000	0,0000
Akta = Keputusan Yayasan	0,0000	0,0000
Akta = Lainnya	0,0000	0,0000
Jumlah penghadap	0,0000	0,0000
Hari = Jumat	0,0000	0,0000

Hanya 1 kolom mempunyai mean positif. Kolom yang tidak dipakai pohon final dapat mempunyai importance nol. Nilai negatif juga disimpan dan dibahas pada halaman berikutnya; nilainya tidak dianggap sebagai tambahan mutu prediksi.

D.1 Pembacaan hasil dalam kegiatan kantor

Kolom dengan mean positif terbesar adalah Hari = Kamis, sebesar 0,0157. Hari penerimaan memberi konteks jadwal kerja. Pola hari tertentu perlu diuji pada periode lain karena jumlah berkas sedikit dan tidak ada informasi jam masuk maupun kalender hari libur.

Pada beberapa kolom, pengacakan justru menaikkan AP. Nilai negatif paling besar terdapat pada Bulan cos (-0,0383), Bulan sin (-0,0062), Akta = PKR PT (-0,0025). Hasil ini menunjukkan ketergantungan model pada pola yang belum membantu prediksi test, bukan alasan untuk menghapus fitur berdasarkan test lalu menilai ulang pada test yang sama.

Pengacakan bersama menurut fitur asal

Fitur asal atau kelompok	Mean penurunan AP	Simpangan baku
Hari masuk	0,0150	0,0158
Jumlah penghadap	0,0000	0,0000
Antrean awal hari	0,0000	0,0000
SLA hari	0,0000	0,0000
RUPS tersedia saat masuk	0,0000	0,0000
Kategori akta	-0,0023	0,0124
Bulan sin	-0,0053	0,0295
Bulan cos	-0,0420	0,0594

Kolom kategori akta dan hari masuk dipindahkan bersama dalam kelompoknya. Dengan demikian satu berkas tetap memiliki kombinasi kategori yang valid. Hasil kelompok membantu membaca pengaruh kategori secara utuh, sedangkan grafik sebelumnya menunjukkan kolom individual.

Urutan kedua dan ketiga pada Top 10, yaitu SLA dan antrean, sama-sama bernilai nol. Peringkat antarfitur yang seri tidak menunjukkan mana yang lebih penting. SLA tetap penting untuk mendefinisikan keterlambatan; antrean memberi konteks pekerjaan yang terbuka. Pohon final belum memakai keduanya dalam percabangan.

Kalender dan kategori layanan

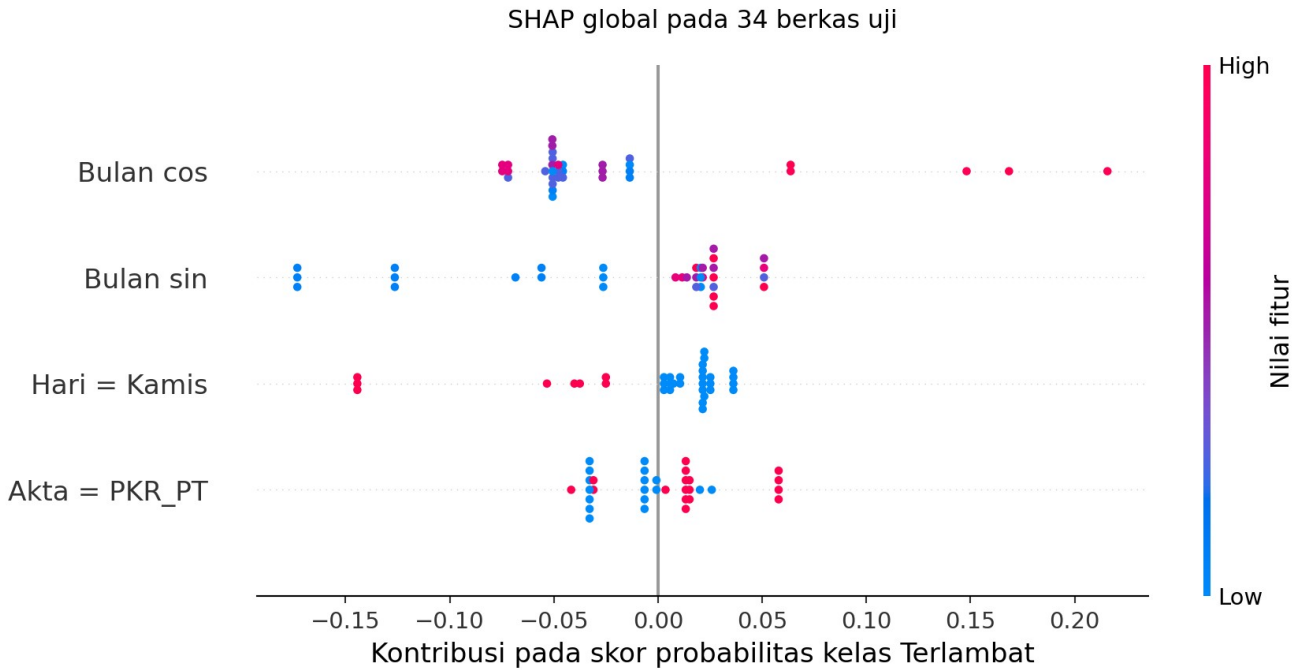
Bulan sin dan cos perlu dibaca bersama sebagai siklus tahunan. Pengacakan satu koordinat dapat memutus hubungan pasangan tersebut. Kategori akta memberi konteks tahapan layanan, tetapi bukan pengganti instansi tujuan. Ketergantungan pada kalender perlu diuji pada periode lain.

Permutation importance dan SHAP menjelaskan penggunaan fitur oleh model. Keduanya tidak membuktikan penyebab keterlambatan. Penjelasan proses masih memerlukan catatan instansi tujuan, kelengkapan awal, dan waktu tunggu yang benar-benar dicatat di kantor.

E. MODEL EXPLAINABILITY MENGGUNAKAN SHAP GLOBAL DAN LOKAL

E.1 Penjelasan global melalui beeswarm

Kami memakai TreeExplainer dari shap 0.49.1, dengan pendekatan interventional dan output probability untuk kelas terlambat. Background efektif terdiri dari 100 baris train. Test tidak menjadi background. Dari 25 kolom, 4 memiliki kontribusi tidak nol dan ditampilkan. [7]



Gambar 4. SHAP beeswarm pada 34 berkas uji.

Titik di sebelah kanan menaikkan skor keterlambatan dan titik di kiri menurunkannya. Merah menunjukkan nilai fitur lebih tinggi, sedangkan biru menunjukkan nilai lebih rendah. Pada indikator kategori, nilai 1 berarti kategori tersebut hadir dan 0 berarti tidak hadir.

Bulan cos. Pada nilai sampai -0,50, rata-rata kontribusi SHAP adalah -0,0421; pada nilai mulai 0,50, rata-ratanya 0,0318.

Bulan sin. Pada nilai sampai -0,87, rata-rata kontribusi SHAP adalah -0,0505; pada nilai mulai 0,50, rata-ratanya 0,0268.

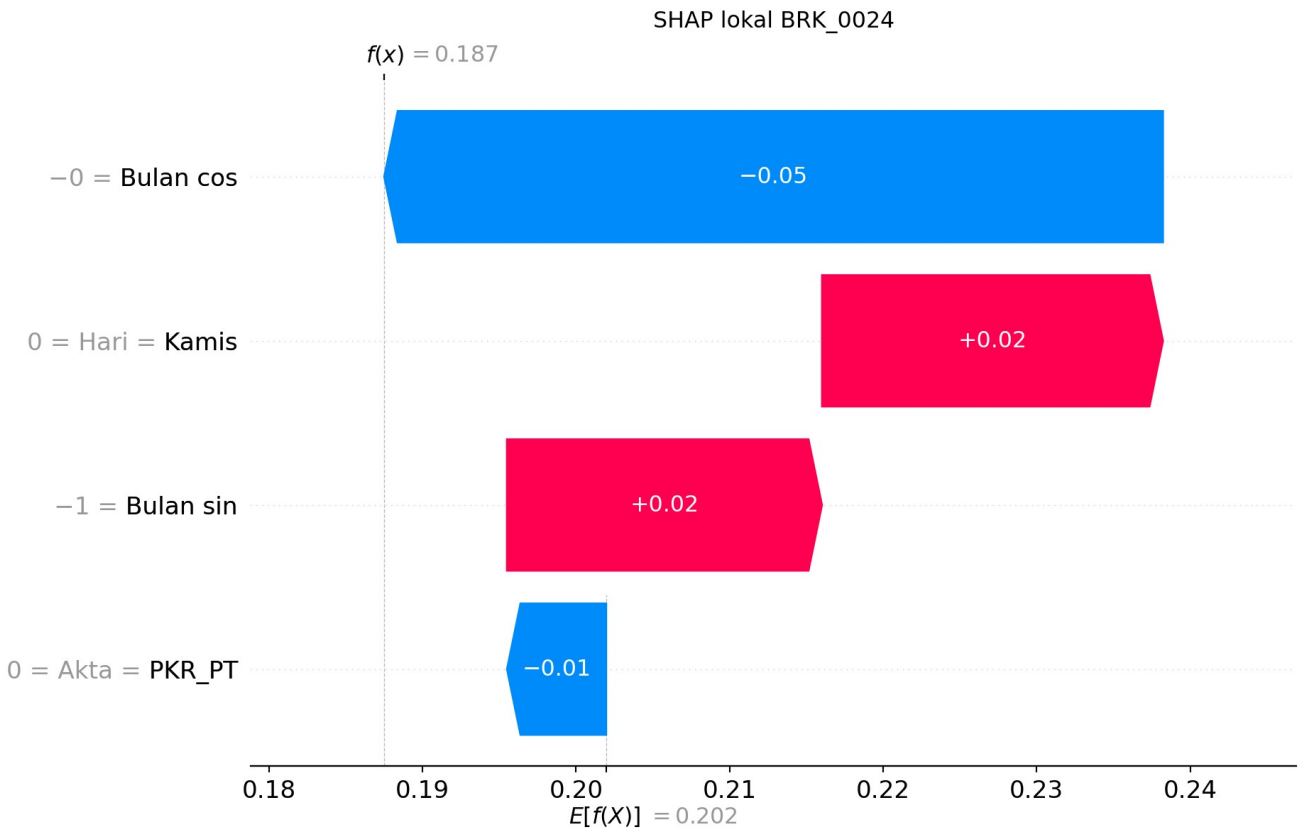
Hari = Kamis. Pada nilai sampai 0,00, rata-rata kontribusi SHAP adalah 0,0189; pada nilai mulai 1,00, rata-ratanya -0,0768.

Akta = PKR PT. Pada nilai sampai 0,00, rata-rata kontribusi SHAP adalah -0,0132; pada nilai mulai 1,00, rata-ratanya 0,0151.

Arah tersebut berlaku pada sampel yang sedang dijelaskan. Dominasi fitur kalender perlu dibaca hati-hati karena prediksi model masih lemah. Skor pohon juga belum dikalibrasi menjadi peluang keterlambatan yang dapat langsung dipakai sebagai janji layanan.

E.2 Waterfall pada satu berkas kritis

Identitas kasus	Hasil
ID dan posisi	BRK_0024; urutan test 6; baris data sumber 24, di luar header.
Kategori dan tanggal masuk	AJB Saham; 2024-09-17
Aktual dan prediksi	Aktual terlambat; prediksi pada 0,50 = 0; prediksi pada 0,11 = 1.
Nilai dasar dan skor akhir	E[f(x)]=0,20196; jumlah SHAP=-0,01446; f(x)=0,18750



Gambar 5. SHAP waterfall untuk BRK_0024.

Pendorong skor terbesar pada berkas ini adalah Hari = Kamis=0,00 (+0,0222) dan Bulan sin=-1,00 (+0,0205). Kontribusi merah menjelaskan perubahan dari nilai dasar model, bukan tambahan hari pengerjaan. Indikator hari atau kategori bernilai 0 menunjukkan ketidakhadiran kategori tersebut, sehingga harus dibaca bersama kategori aktual pada tabel.

Penekan skor terbesar adalah Bulan cos=0,00 (-0,0507) dan Akta = PKR PT=0,00 (-0,0065). Semua kontribusi membentuk skor akhir 0,18750. Skor ini berada di bawah 0,50 tetapi melewati ambang 0,11, sehingga keputusan berubah menjadi berisiko. Berkas benar-benar terlambat, tetapi contoh ini tidak mewakili seluruh kesalahan model.

E.3 Kontribusi angka dan aturan percabangan

Berkas BRK_0024 mempunyai 2 penghadap, SLA 10 hari, serta antrean awal hari 1 berkas dalam histori latih. Indikator RUPS tersedia bernilai 0. Nilai tersebut berasal dari catatan berkas dan transformasi yang telah ditetapkan sebelum test.

Fitur	Nilai	Kontribusi SHAP	Arah
Bulan cos	0,000	-0,05073	Turun
Hari = Kamis	0,000	+0,02221	Naik
Bulan sin	-1,000	+0,02052	Naik
Akta = PKR PT	0,000	-0,00646	Turun

Penjumlahan SHAP diperiksa pada seluruh test. Galat maksimum terhadap skor model adalah 1.16e-08. Untuk kasus ini, 0,201961 ditambah -0,014461 menghasilkan 0,187500. Nilai dasar adalah rata-rata skor model pada background train, bukan proporsi keterlambatan aktual.

Aturan yang dilewati berkas pada pohon final

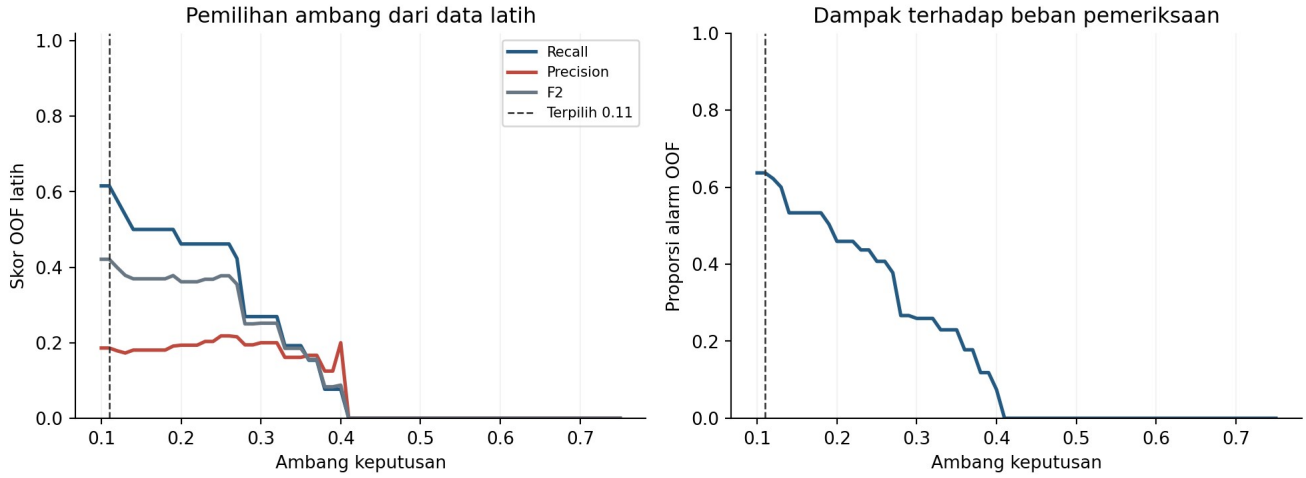
No	Fitur	Nilai dan batas percabangan
1	Bulan cos	0,000 <= 0,683
2	Hari = Kamis	0,000 <= 0,500
3	Bulan sin	-1,000 <= -0,683
4	Bulan sin	-1,000 <= -0,933

Koordinat bulan bukan tanggal kalender langsung. SHAP juga tidak harus sama dengan satu aturan pohon karena kontribusinya dibandingkan terhadap berbagai kombinasi fitur. Keduanya digunakan untuk menjelaskan bagaimana skor terbentuk, bukan untuk menetapkan penyebab keterlambatan.

Jika model dipakai dalam uji terawasi, staf tetap memeriksa posisi pengurusan, persyaratan yang belum lengkap, dan kebutuhan tindak lanjut. Skor risiko tidak menggantikan pemeriksaan berkas maupun keputusan Notaris/PPAT. Dengan mutu prediksi saat ini, model belum layak menjadi dasar prioritas otomatis.

E.4 Pemilihan ambang dan beban pemeriksaan

Ambang dipilih dari prediksi out-of-fold pada train, dari 0,10 sampai 0,75 dengan langkah 0,01. Sasaran F2 memberi bobot lebih besar pada recall. Jika F2 sama, precision lebih tinggi didahulukan, lalu ambang terbesar. Test tidak digunakan untuk memilih ambang. [8]



Gambar 6. Skor dan proporsi alarm berdasarkan OOF train.

```
from sklearn.base import clone
from sklearn.model_selection import cross_val_predict
from analisis_tugas04_kantor import choose_threshold, cv5

p_oof = cross_val_predict(
    clone(best_model), X_train, y_train, cv=cv5(),
    method="predict_proba", n_jobs=2)[:, 1]
threshold, hasil_oof = choose_threshold(y_train, p_oof)
# Parameter dan threshold disimpan sebelum test dinilai.
```

Ambang terpilih adalah 0,11. Pada test, 22 berkas menerima alarm dan 4 di antaranya benar-benar terlambat. Precision 18,2% menunjukkan sebagian besar alarm masih salah. AP tidak berubah karena ambang hanya mengubah keputusan kelas, bukan urutan skor model.

Kantor perlu menentukan berapa banyak pemeriksaan tambahan yang dapat dilakukan staf dan seberapa besar kerugian jika keterlambatan terlewat. Informasi biaya dan kapasitas itu belum tersedia, sehingga kami tidak memasukkan angka perkiraan. Pengujian berikutnya dapat memakai batas jumlah alarm yang disepakati sebelum melihat data periode baru.

Tindak lanjut catatan dosen dan batas penggunaan data

Catatan dosen	Yang dikerjakan pada Tugas 04	Hal yang masih diperlukan
Sampel 169 dan test hanya 7 positif	5-fold CV, nested CV, bootstrap, serta diagnosis gap.	Tambahan catatan berkas dari periode lain.
Fitur eksternal dan ceklis awal	169 ID diperiksa; nilai sumber, durasi, target, dan status ketersediaan data direkap.	Instansi tujuan aktual, jumlah item wajib, dan jumlah item valid saat awal belum tercatat pada sumber.
TreeExplainer dan threshold moving	Beeswarm, waterfall, jalur pohon, serta uji 0,50; 0,25; dan OOF.	Validasi manfaat alarm bersama staf.

Data sumber memuat sepuluh kolom. Instansi tujuan dan kelengkapan awal belum tercatat, sehingga keduanya belum dapat dipakai sebagai prediktor. Kami tidak menyimpulkan tujuan BPN, AHU, KPP Pratama, atau Bapenda hanya dari nama akta. Pengumpulan berikutnya perlu mencatat tujuan sebenarnya beserta sumber verifikasinya. [2]

Fitur yang digunakan dan waktu ketersediaannya

Fitur	Definisi	Batas waktu informasi
Jumlah penghadap; SLA	Nilai pada rekap berkas.	Sudah ditetapkan ketika berkas diterima.
Antrean berjalan	Berkas latih lain yang masuk sebelum hari penerimaan dan belum selesai sebelum hari itu.	Histori hanya dari fold latih.
Ada RUPS	1 jika tanggal tersedia dan tidak sesudah tanggal masuk.	Tanggal masa depan dianggap belum tersedia.
Bulan sin dan cos	Koordinat siklus bulan dari tanggal masuk.	Dihitung dari tanggal penerimaan.
Kategori akta; hari masuk	Kategori pada rekap dan nama hari dari tanggal masuk.	Tidak memakai hasil penyelesaian.

Tanggal akta, nomor urut, dan nomor bulanan tidak menjadi fitur model. Tanggal selesai digunakan untuk membentuk target dan untuk status historis berkas latih lain; tanggal selesai sampel prediksi tidak memengaruhi fiturnya. Pengujian kode memastikan bahwa mengganti tanggal selesai seluruh test tidak mengubah probabilitas prediksi.

Pemeriksaan waktu tambahan memakai cutoff 2026-06-04: 134 berkas yang sudah selesai menjadi train, 0 berkas belum selesai dikeluarkan, dan 35 berkas setelah cutoff menjadi test. AP 0,132 dan recall 0,500. Ini hanya pemeriksaan sensitivitas pada dataset yang sama; parameter sebelumnya dipilih pada random split sehingga hasil ini bukan validasi masa depan yang sepenuhnya independen.

F. LEMBAR KOMITMEN DAN INTEGRITAS AKADEMIK KELOMPOK

Kami menyusun laporan berdasarkan 169 catatan berkas kantor. Nilai sumber tidak diubah untuk memperbaiki skor. Target dihitung dari selisih tanggal selesai dan tanggal masuk terhadap SLA. Seluruh penalaan, evaluasi, permutation importance, dan SHAP memiliki kode serta hasil angka yang dapat diperiksa ulang.

Hasil yang belum baik tetap dilaporkan, termasuk recall nol pada ambang tertentu dan banyaknya alarm palsu. Pengembangan kode serta penyuntingan naskah menggunakan bantuan AI. Kelompok bertanggung jawab memeriksa hasil, memahami metode, dan memastikan penjelasan sesuai data sebelum pengumpulan.

Tempat dan tanggal	Koordinator tim	Tanda tangan koordinator
Jakarta, 22 Oktober 2026	Muhammad Rizqi Saputra NIM 12250158	Muhammad Rizqi Saputra NIM 12250158

Referensi

[1] Kelompok 02. Laporan Tugas 03 Pembelajaran Mesin. Kantor Notaris & PPAT Aries Buwana. 15 Oktober 2026.

[2] Saputra, I. Rekap Evaluasi dan Feedback Tugas 03. 16 Oktober 2026, halaman 3 sampai 4, bagian Kelompok 02.

[3] Saputra, I. Panduan dan Template Tugas 04 Pembelajaran Mesin. Semester Gasal 2026/2027.

[4] Scikit-learn 1.8. Common pitfalls and recommended practices. https://scikit-learn.org/1.8/common_pitfalls.html

[5] Scikit-learn 1.8. Nested versus non-nested cross-validation. https://scikit-learn.org/1.8/auto_examples/model_selection/plot_nested_cross_validation_iris.html

[6] Scikit-learn 1.8. Permutation feature importance. https://scikit-learn.org/1.8/modules/permutation_importance.html

[7] SHAP. TreeExplainer. https://shap.readthedocs.io/en/latest/generated/shap.TreeExplainer.html

[8] Scikit-learn 1.8. Tuning the decision threshold for class prediction. https://scikit-learn.org/1.8/modules/classification_threshold.html

Sumber data: berkas_notaris_terisi (2).csv, 169 baris dan 10 kolom. Dokumentasi daring diakses 22 Oktober 2026.

Lampiran Reproduksi analisis dan pemetaan rubrik

Komponen penilaian	Bobot	Bukti
Ruang parameter dan strategi tuning	25%	Lima parameter, 320 kandidat, 5-fold CV, pipeline, dan objective AP.
Perbandingan baseline dan tuned	25%	Train/CV/test, delta, gap, confusion matrix, kurva, dan bootstrap.
Permutation feature importance	25%	Top 10 pada test, 100 pengacakan, kelompok kategori, dan interpretasi nilai nol maupun negatif.
SHAP global dan lokal	25%	Beeswarm, waterfall, nilai dasar, kontribusi numerik, jalur pohon, serta dua paragraf interpretasi kasus.

Tabel di atas memetakan bukti analisis ke empat komponen rubrik resmi. Bagian utama mengikuti urutan A sampai F pada template dosen; lampiran ini melengkapi cara pemeriksaan ulang.

Cara menjalankan ulang

Berkas pendamping menyimpan sumber data, kode, ID pembagian data, seluruh kandidat tuning, model terlatih, prediksi test, dan nilai SHAP. Sumber data disalin tanpa mengubah isinya ke data/berkas_notaris.csv. Dengan Python 3.12, jalankan dari folder utama:

```
python -m pip install -r requirements.txt
python work/analisis_tugas04_kantor.py \
    --csv data/berkas_notaris.csv \
    --out work/hasil_tugas04_kantor --jobs 2
```

Notebook Colab disediakan untuk menjalankan prosedur yang sama. Bukti eksekusi laporan adalah log dan hasil numerik yang tersimpan; notebook tidak diberi keluaran seolah-olah sudah dijalankan. Seed 42, versi paket, dan hash sumber membantu pemeriksaan ulang.

Identitas sumber

SHA256 sumber: 686aa269511d6eb26ad661ebfde499ffbfd64383de4e84e93ea54ab23905785b

Lingkungan	Versi
Python; NumPy; pandas	3.12.14; 2.3.5; 2.2.3
Scikit-learn; SciPy; SHAP	1.8.0; 1.17.0; 0.49.1
Matriks akhir	8 fitur sebelum encoding; 25 kolom setelah encoding train.

Koordinator mengesahkan Bagian F dan mengunggah PDF dengan nama TUGAS_04_KELOMPOK_02_NOTARIS_PPAT.pdf melalui LMS/EL-NUSA. Tenggat pada panduan adalah Kamis, 22 Oktober 2026 pukul 23:59:59 WIB. [3]

Lampiran Pemeriksaan dan isian rekap berkas

Rekap pendamping telah disusun untuk seluruh 169 ID dengan mempertahankan sepuluh kolom sumber. Lama penyelesaian, selisih terhadap SLA, target terlambat, dan status ketepatan dihitung dari tanggal serta SLA. Informasi yang belum tersedia diberi status tertulis agar berbeda dari nilai nol atau tidak berlaku.

Informasi	Hasil pemeriksaan	Isian pada rekap
Identitas, kategori, jumlah penghadap, dan SLA	Tersedia pada 169 berkas.	Nilai mengikuti sumber; tidak diganti berdasarkan dugaan.
Tanggal masuk dan tanggal selesai	Tersedia pada 169 berkas.	Dipakai menghitung durasi hari kalender dan target.
Tanggal RUPS	13 tercatat dan 156 kosong; 10 dari 13 terjadi setelah tanggal masuk.	Nilai sumber dipertahankan. Fitur awal bernilai 1 hanya jika tanggal RUPS tidak melampaui tanggal masuk.
Instansi tujuan aktual	Kolom tidak ada pada sumber.	Belum tercatat untuk 169 ID.
Item wajib dan item valid saat masuk	Kedua kolom tidak ada pada sumber.	Belum tercatat untuk 169 ID.
Skor ceklis awal	Pembilang dan penyebut belum tersedia.	Belum tercatat; tidak diberi angka 0 maupun 100%.

Pencocokan beberapa baris dengan sumber

ID berkas	Kategori	Durasi hari	SLA hari	Status
BRK_0001	Kuasa	10	5	Terlambat
BRK_0002	Pendirian PT	11	14	Tepat waktu
BRK_0003	PKR PT	10	14	Tepat waktu

Pemeriksaan yang sama diterapkan pada seluruh baris dan menghasilkan 33 berkas terlambat serta 136 tepat waktu. Semua ID pada rekap dapat dicocokkan dengan sumber. Durasi, selisih SLA, dan status ketepatan merupakan hasil penyelesaian, sehingga tidak dimasukkan sebagai fitur prediksi awal.

Jumlah penghadap menunjukkan jumlah orang, sedangkan tanggal RUPS menunjukkan waktu peristiwa. Keduanya tidak menentukan jumlah dokumen wajib atau dokumen yang sudah valid saat penerimaan. Tujuan instansi juga tidak ditetapkan hanya dari nama kategori akta.

Rekomendasi dosen mengenai instansi tujuan dan skor ceklis awal belum dapat diuji sebagai fitur tambahan pada analisis ini. Pengembangan berikutnya membutuhkan catatan penerimaan yang mencantumkan tujuan pengurusan, item wajib, item valid, waktu pemeriksaan, serta rujukan arsipnya. Evaluasi sesudah penambahan fitur perlu memakai data uji baru.